NSL-KDD ile Saldırı Tespiti

Derin Öğrenme & Anomali Tespiti

Ödev 1: CNN & AE-CNN Karşılaştırması
Ödev 2: VAE ile Anomali Tespiti

Dide Şengül — 152120221041

Ata Can Özcihan — 152120221103

2025-2026

Ödev 1 – CNN ve AE-CNN ile Saldırı Tespiti

1.1 Giriş

Bu çalışmada NSL-KDD veri seti kullanılarak ağ trafiği üzerinde ikili sınıflandırma (normal / saldırı) gerçekleştirilmiştir. Doğrudan CNN tabanlı sınıflandırıcı ile Autoencoder'ın encoder kısmının özellik çıkarımı olarak kullanıldığı AE-CNN birleşik mimarisi karşılaştırılmıştır.

1.2 Veri Seti

Özellik	Değer
Toplam özellik sayısı	41
Eğitim seti (KDDTrain+)	125.973 örnek
Test seti (KDDTest+)	22.544 örnek
Normal / Saldırı (test)	9.711 / 12.833
Kategorik özellikler	protocol_type, service, flag
Saldırı kategorileri	DoS, Probe, R2L, U2R

1.3 Model Mimarileri

1.3.1 CNN Modeli

Ham özellikler üzerinden çalışan 1D evrişimli sinir ağıdır. 3 adet Conv1D katmanı (64→128→64 filtre), BatchNormalization, MaxPooling ve Dropout(0.3) içeren tam bağlantılı katmanlardan oluşmaktadır.

1.3.2 AE-CNN Modeli

İlk aşamada bir Autoencoder (128→64→32 gizli boyut) sadece rekonstrüksiyon görevi için eğitilmiştir. Ardından Encoder kısmı dondurularak (trainable=False) CNN sınıflandırıcısına bağlanmıştır. Bu sayede denetimsiz özellik öğrenimi denetimli sınıflandırma ile birleştirilmiştir.

1.4 Eğitim Süreci

CNN – Eğitim Grafikleri

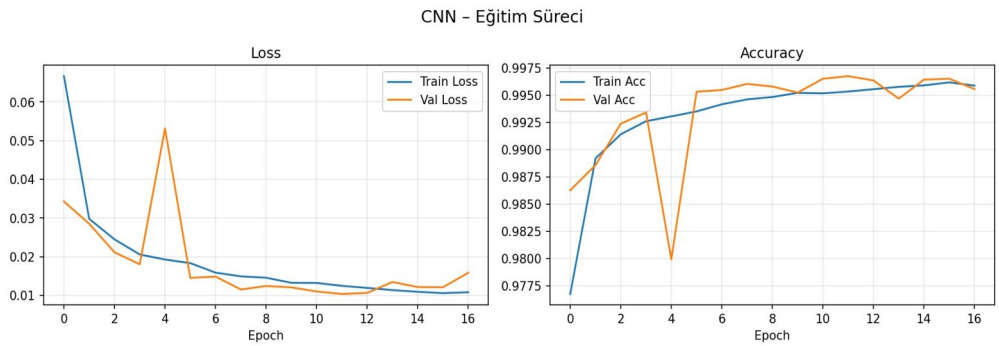

CNN modeli 17 epoch'ta erken durdurma ile tamamlanmıştır. 4. epoch'ta görülen validation loss spike'ı geçici bir mini-batch dalgalanmasından kaynaklanmakta olup model hızla toparlanmıştır. Final doğruluk değerleri ~%99.5 civarında sabitlenmiştir.

AE-CNN – Eğitim Grafikleri

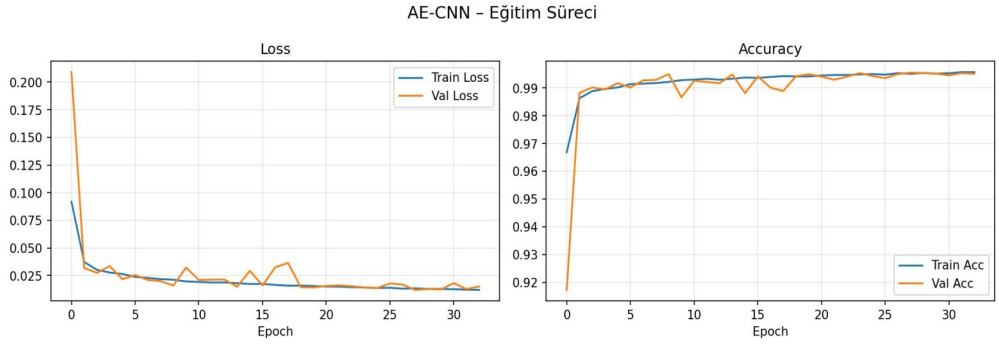

AE-CNN modeli yaklaşık 33 epoch'ta erken durdurma ile tamamlanmıştır. İlk epoch'ta yüksek başlayan validation loss hızla düşmüş ve eğitim ile doğrulama eğrileri birbirine yakınsamıştır.

1.5 Test Sonuçları

CNN – Confusion Matrix

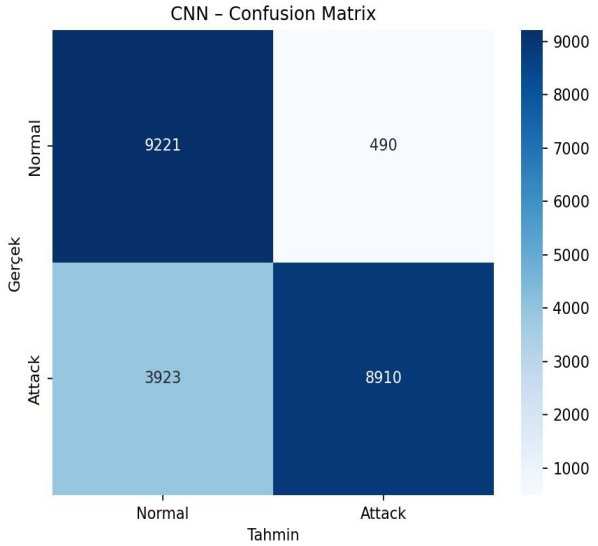

AE-CNN – Confusion Matrix

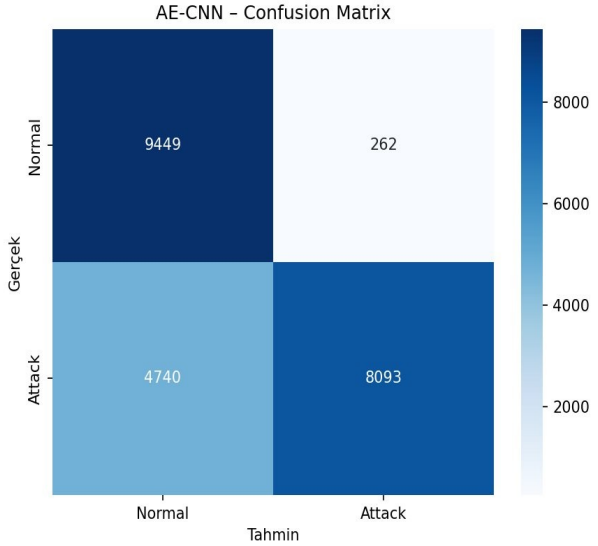

1.6 Performans Metrikleri

Metrik	CNN	AE-CNN
Accuracy	0.8040	0.7781
Precision	0.9480	0.9686
Recall	0.6940	0.6306
F1-Score	0.8020	0.7639
TN (Normal doğru)	9.221	9.449
FP (Normal → Saldırı)	490	262
FN (Saldırı → Normal)	3.923	4.740
TP (Saldırı doğru)	8.910	8.093

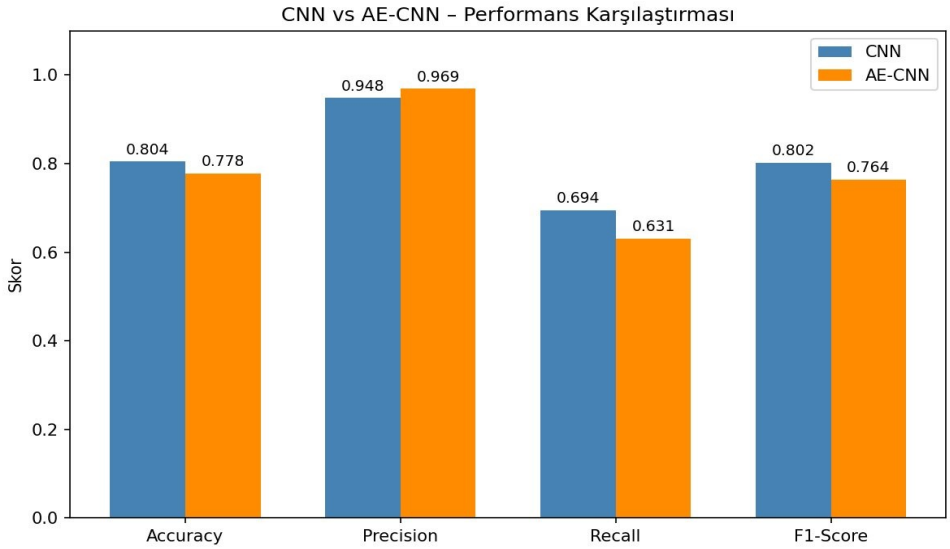

1.7 Sonuç ve Yorum

CNN modeli tüm metriklerde AE-CNN'den daha iyi sonuç vermiştir. Her iki modelin Recall değerinin (~%63-69) düşük olması NSL-KDD'nin bilinen bir zorluğundan kaynaklanmaktadır: test seti, eğitim setinde görülmeyen yeni saldırı tiplerini içermektedir (R2L, U2R gibi kategoriler çok az örnekle temsil edilmektedir).

AE-CNN'nin Precision değeri daha yüksektir (0.969 vs 0.948), yani saldırı dediğinde daha az yanlış alarm üretmektedir. Ancak daha fazla saldırıyı kaçırmaktadır (FN: 4.740 vs 3.923). Güvenlik senaryolarında Recall genellikle daha kritik olduğundan CNN bu ödevde daha tercih edilebilir bir modeldir.

Ödev 2 – VAE ile Anomali Tespiti

2.1 Giriş

Bu çalışmada Variational Autoencoder (VAE) kullanılarak denetimsiz anomali tespiti gerçekleştirilmiştir. VAE yalnızca 67.343 normal trafik örneği ile eğitilmiş; test aşamasında rekonstrüksiyon hatası tabanlı bir eşik mekanizması ile saldırılar tespit edilmiştir.

2.2 VAE Mimarisi ve Eğitim

Encoder: Girdi (41) → Dense(128,ReLU) → Dense(64,ReLU) → [μ, log σ²] (latent_dim=16)
Örnekleme: $z = \mu + \varepsilon \cdot \exp(0.5 \cdot \log \sigma^2)$ [Reparameterization Trick]
Decoder: z (16) → Dense(64,ReLU) → Dense(128,ReLU) → Çıktı (41)

Loss = Rekonstrüksiyon Loss (MSE) + β · KL Divergence (β = 1.0)
Eşik: Normal eğitim verisinin %95. persentili = 0.3803

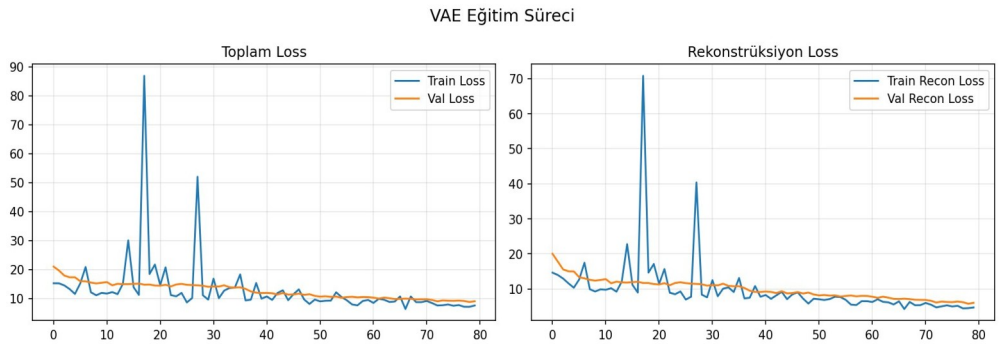

VAE 80 epoch boyunca eğitilmiştir. 15-17. ve 26-28. epoch'larda görülen ani loss spike'ları KL terimindeki geçici dengesizlikten kaynaklanmaktadır. Validation loss istikrarlı bir şekilde düşerek ~8-9 seviyesinde sabitlenmiştir.

2.3 Rekonstrüksiyon Hatası ve Eşik Analizi

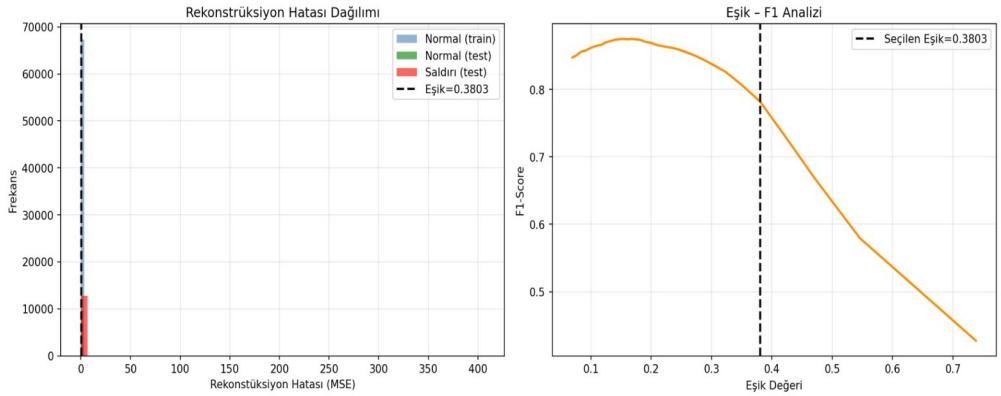

Sol grafik: Normal trafik örnekleri sıfıra yakın MSE üretirken, saldırı örneklerinin bir kısmı daha yüksek hata göstermektedir. Eşik değeri 0.3803 olarak belirlenmiştir. Sağ grafik: Eşik değeri düştükçe F1 artmakta; ~0.1-0.15 civarında zirveye ulaşmaktadır. %95 persentil eşiği (0.3803) precision-recall dengesini koruyarak seçilmiştir.

2.4 ROC Eğrisi

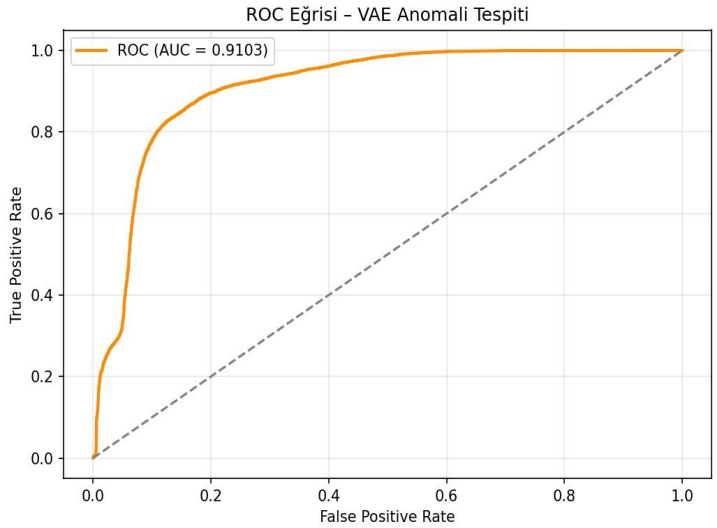

ROC-AUC = 0.9103. Eğri sol üst köşeye belirgin şekilde yaklaşmakta olup modelin rastgele tahmin (AUC=0.5) ile kıyaslandığında güçlü bir ayrım gücüne sahip olduğunu göstermektedir.

2.5 Confusion Matrix

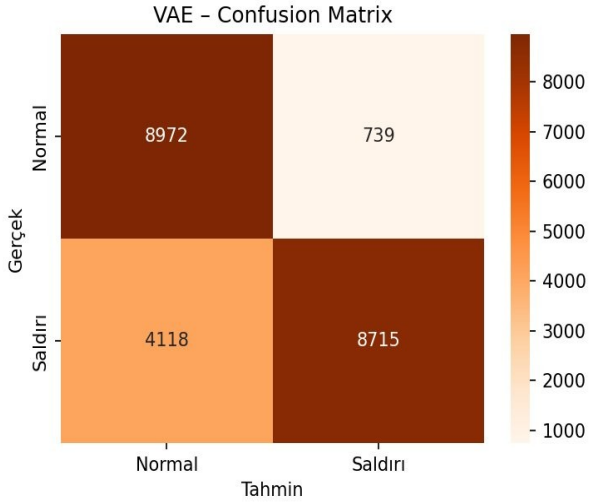

2.6 Performans Metrikleri

Metrik	Değer	Açıklama
ROC-AUC	0.9103	Güçlü ayrım gücü
Precision	0.9217	8715 / (8715+739)
Recall	0.6792	8715 / (8715+4118)
F1-Score	0.7824	Precision-Recall dengesi
FPR	0.0761	739 / (739+8972) — düşük yanlış alarm
TN	8.972	Normal olarak doğru tahmin
FP	739	Normal trafik yanlış saldırı
FN	4.118	Kaçırılan saldırı

TP	8.715	Tespit edilen saldırı

2.7 Sonuç ve Yorum

VAE tabanlı anomali tespiti, herhangi bir saldırı etiketi kullanmadan AUC=0.91 değerine ulaşmıştır. FPR=%7.6 ile normal trafik üzerindeki yanlış alarm oranı kabul edilebilir düzeydedir. Recall=%67.9 oranında saldırı tespit edilebilmektedir.

Eşik değerinin 0.38'den 0.10-0.15 aralığına düşürülmesi F1 skorunu yaklaşık %86'ya çıkarabilecektir; ancak bu durumda FPR da artacaktır. Güvenlik gereksinimlerine göre eşik optimize edilebilir.

Denetimsiz yaklaşımın en büyük avantajı, eğitim sırasında hiç görmediği saldırı tiplerini de tespit edebilmesidir. Bu özellik onu sıfır gün (zero-day) saldırılarına karşı denetimli modellere göre daha dayanıklı kılmaktadır.

Genel Karşılaştırma: CNN, AE-CNN ve VAE

Metrik / Özellik	CNN	AE-CNN	VAE
Accuracy	0.804	0.778	–
Precision	0.948	0.969	0.922
Recall	0.694	0.631	0.679
F1-Score	0.802	0.764	0.782
ROC-AUC	–	–	0.910
FPR	0.050	0.027	0.076
Öğrenme tipi	Denetimli	Denetimli+Denetimsiz	Denetimsiz
Etiket ihtiyacı	Evet	Evet	Sadece normal
Eğitim süresi	~2 dk	~10 dk	~8 dk
Zero-day dayanıklılığı	Düşük	Orta	Yüksek

CNN, hız ve genel başarım açısından öne çıkmaktadır. AE-CNN daha yüksek Precision ile daha az yanlış alarm üretmektedir. VAE, etiket gerektirmeden güçlü bir AUC değerine ulaşmakta ve bilinmeyen saldırı tiplerinde avantaj sağlamaktadır.

Kaynaklar

- Tavallaee, M. et al. "A detailed analysis of the KDD CUP 99 data set." CISDA, 2009.
- Kingma, D. P., & Welling, M. "Auto-encoding variational bayes." ICLR, 2014.
- LeCun, Y. et al. "Deep learning." Nature, 521(7553), 436–444, 2015.
- TensorFlow / Keras Documentation – https://www.tensorflow.org
- NSL-KDD Dataset – https://www.unb.ca/cic/datasets/nsl.html